Wsparcie analizy artykułów prasowych z wykorzystaniem narzędzi AI

Ryszard Nowak[1] Maciej Grydyk[2]

2026

Streszczenie

Stronniczość mediów oraz powszechna manipulacja są istotnymi problemami współczesnego odbiorcy. Zbadano możliwości analizy artykułów prasowych pod tym kątem przez modele językowe. Zaproponowany system stworzony przy użyciu *CrewAI* dokonuje trafnej analizy wybranych wypowiedzi, co pozwala wnioskować o skuteczności podejścia i uzasadnia dalszy rozwój. Przeanalizowano dostępną literaturę oraz zbiory danych konieczne do ewaluacji przyszłych rozwiązań.

Keywords: analiza mediów, sieci neuronowe, duże modele językowe, systemy agentowe, Langchain, CrewAI

1 Wstęp i przegląd aktualnego stanu badań

Współczesne media odgrywają kluczową rolę w kształtowaniu opinii publicznej, dostarczając informacji, które wpływają na postrzeganie wydarzeń społecznych, politycznych i gospodarczych. Wraz z rosnącą dostępnością treści informacyjnych w formie cyfrowej, rośnie również potrzeba ich krytycznej analizy, szczególnie w kontekście wiarygodności oraz sposobu prezentowania faktów. Jest to szczególnie ważne w kontekście powszechnie szerzonej dezinformacji oraz tzw. *fake newsów* coraz częściej pojawiających się w mediach.

Manipulacja w artykułach prasowych nie musi przyjmować formy oczywistej dezinformacji. Częściej występuje w postaci doboru emocjonalnie nacechowanego słownictwa, selektywnego eksponowania określonych informacji lub zmian w tonie wypowiedzi, czyli tzw. *biasu*. Takie zmiany mogą prowadzić do stronniczości przekazu, nawet gdy przekazywane dane są technicznie poprawne. Praca [7] przedstawia podział na 17 rodzajów. Część z nich przedstawionych zostało na grafice 1. Ze względu na złożoność zjawiska, jego spostrzeżenie może stanowić duże wyzwanie dla odbiorcy.

Rozwój dużych modeli językowych otwiera nowe możliwości w zakresie automatyzacji analizy tekstu. Modele te pozwalają na interpretację tekstów w sposób zbliżony do ludzkiego rozumienia kontekstu, co czyni je potencjalnie przydatnymi narzędziami do wykrywania subtelnych zmian w narracji i tonie wypowiedzi. Porównując kolejne publikacje dotyczące tego samego tematu, można

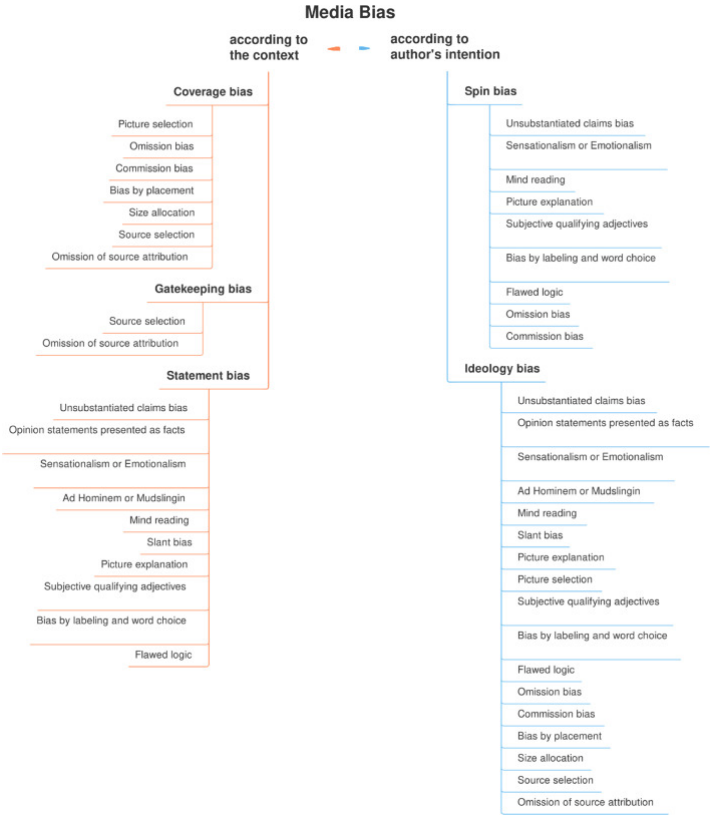

Rysunek 1: Hierarchiczna struktura klasyfikacji zjawiska stronniczości medialnej. Grafika z pracy [7]

identyfikować zmiany w retoryce, które mogłyby wskazywać na zmianę intencji komunikacyjnej lub próbę wpłynięcia na sposób interpretacji wydarzeń przez odbiorcę.

1.1 Cele

Celem opracowania jest zaprezentowanie koncepcji systemu agentowego, który wykorzystuje możliwości *LLM* do analizy ciągłości narracyjnej i wykrywania potencjalnych manipulacji w artykułach prasowych. Proponowane podejście ma na celu wspomaganie oceny jakości przekazu medialnego oraz zwiększenie przejrzystości informacji w obiegu publicznym.

1.2 Podejście w istniejącej literaturze

W ostatnich latach publikowane są coraz liczniejsze analizy rzetelności przekazu medialnego, w tym wykrywania manipulacji, stronniczości oraz zniekształceń narracyjnych.

W badaniu [6] autorzy analizują rozbieżności między oceną stronniczości dokonywaną przez modele językowe a oceną człowieka. Praca ta podkreśla, że choć *LLM* potrafią wykrywać elementy *biasu*, ich wrażliwość na kontekst i subtelności językowe różni się od ludzkiej percepcji, co stanowi istotne ograniczenie w zastosowaniach wymagających interpretacji intencji.

Autorzy artykułu [4] proponują złożony model łączący tekst i obrazy w celu bardziej kompleksowej detekcji manipulacji. Dzięki uwzględnieniu warstwy wizualnej, proponowany model uzyskuje względnie dobre wyniki.

Praca [1] opisuje architekturę opartą na współpracujących agentach wykonujących złożone zadania przy użyciu *LangGraph* i *CrewAI*. Autorzy wskazują, że taki podział pracy pomiędzy wyspecjalizowanych agentów poprawia efektywność analizy i umożliwia większą skalowalność w zadaniach związanych z wnioskowaniem nad tekstem. Zapewniony jest również przykład implementacji podobnego, choć realizującego inne cele systemu. Widoczna jest dzięki temu łatwość implementacji proponowanego podejścia.

Choć *LangChain* i *CrewAI* pojawiają się stosunkowo niedawno w literaturze naukowej, coraz więcej opracowań eksploruje ich zastosowanie do budowy modularnych, zautomatyzowanych systemów analitycznych. Podejścia te korzystają z możliwości integracji *LLM* z narzędziami wykonawczymi, umożliwiając analizę tekstów w kontekście czasu, tematu i źródła. Mimo obiecujących wyników, autorzy wskazują na potrzebę dalszych badań nad spójnością interpretacji modeli oraz ich odpornością na bias wewnętrzny.

Istniejąca literatura dostarcza solidnych podstaw teoretycznych i technicznych dla rozwijania systemów wykrywających manipulacje narracyjne. Należy jednak pamiętać o wymagającym charakterze problemu. *Bias* nie zawsze jest jasno określony, a jego interpretacja zależy od odbiorcy ([6]).

1.3 Zbiory danych

Odpowiednia ewaluacja systemu wymaga zbiorów danych zawierających zarówno oryginalne treści medialne, jak i adnotacje dotyczące stronniczości, tonu, wiarygodności lub charakteru manipulacji. W literaturze dostępnych jest kilka zbiorów danych, które mogą zostać wykorzystane w tym celu, choć nie wszystkie zostały bezpośrednio zaprojektowane z myślą o analizie zmian narracyjnych w czasie. Niemniej jednak, ich struktura i zawartość pozwalają na konstrukcję eksperymentów zbliżonych do realnych scenariuszy.

1.3.1 FA-KES (Fact-Aware Knowledge-Enriched News Dataset)

FA-KES to zbiór artykułów o wojnie syryjskiej, oznaczonych jako wiarygodne lub fałszywe. Przydatny w ocenie skuteczności systemu do wykrywania manipulacji faktami.

1.3.2 FlipBias

FlipBias to zbiór zawierający pary artykułów prezentujących przeciwstawne narracje na ten sam temat. Cechą wyróżniającą tego zbioru jest jego konstrukcja oparta na intencjonalnym *odwróceniu* perspektywy, co pozwala analizować, jak zmieniają się ton, argumentacja i selekcja faktów. Zbiór ten może być przydatny do rozpoznawania *biasu* i porównań między różnymi wersjami tej samej informacji.

1.3.3 BABE

Zbiór zawiera 3700 zdań z oznaczeniami *biasu* na poziomie zdań i słów, adnotowane przez ekspertów. Może okazać się pomocny przy detekcji stronniczości narracji.

1.3.4 Własny zbiór

Dla testów prototypu można zebrać kilkanaście artykułów o podobnym temacie i dokonać manualnej analizy, aby sprawdzić, jak skutecznie radzi sobie z wykrywaniem i opisem różnego rodzaju manipulacji. Mimo braku możliwości weryfikacji przez eksperta oraz mocno ograniczonej wielkości zbioru, wciąż pozwala to na wyprowadzenie wniosków o skuteczności rozwiązania.

2 Opis narzędzi i budowy prototypu

Do zbudowania naszego pomysłu potrzebne będą 3 technologie, które będą stanowić podstawę naszego systemu. Do implementacji zastosowany zostanie język programowania *Python 3*.

2.0.1 LLM

Jako podstawę systemu, wykorzystany zostanie *gemini-2.5-flash* dostępny przez *Google AI Studio* za darmo. Jest to sprawnie działający model z możliwością integracji z resztą naszego procesu dzięki bibliotece *LangChain*. Dzięki wysokim limitom bezpłatnego użytkowania stanowi dobry wybór do celów prototypowania.

2.0.2 LangChain

LangChain to biblioteka programistyczna wspierająca tworzenie aplikacji opartych na dużych modelach językowych. Umożliwia integrację modeli z zewnętrznymi źródłami danych, takimi jak pliki, bazy danych czy interfejsy *API*, oraz definiowanie logiki przetwarzania zapytań. Zapewnia wsparcie dla szerokiego zakresu popularnych *LLM*. Dzięki jej wykorzystaniu wdrożenie do własnej aplikacji wybranego modelu językowego staje się niezwykle prostym zadaniem.

2.0.3 CrewAI

CrewAI to biblioteka umożliwiająca organizację współpracy wielu agentów opartych na modelach językowych w ramach jednego systemu. Zapewnia mechanizmy definiowania ról, celów oraz wzajemnych relacji pomiędzy agentami, co pozwala na tworzenie złożonych struktur decyzyjnych i zadaniowych. *CrewAI* umożliwia koordynację działań agentów w oparciu o przypisane im kompetencje oraz logikę współpracy, co ułatwia budowanie systemów realizujących wieloetapowe procesy przy zachowaniu modularności i skalowalności rozwiązania.

2.1 Architektura

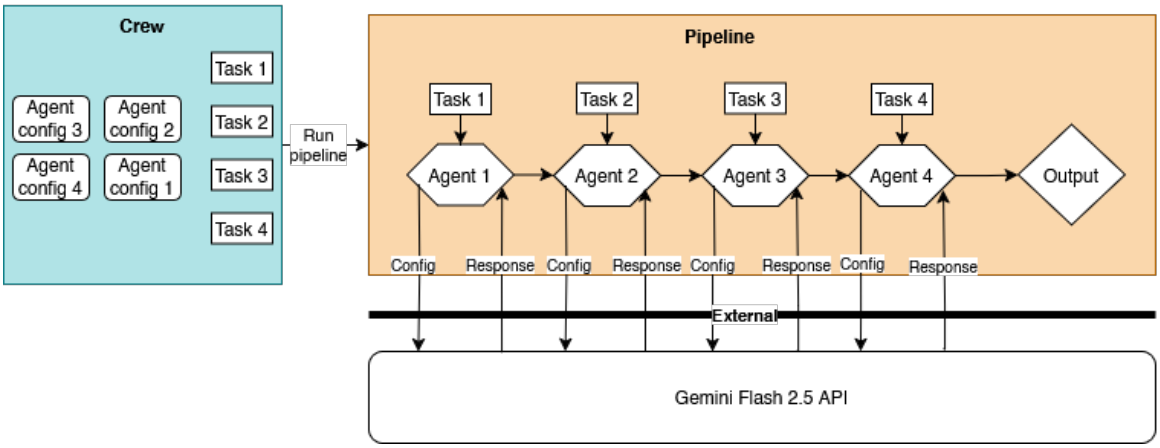

Rysunek 2: Architektura prototypu

System oparty jest na klasie *Crew*, która odpowiada za zarządzanie wszystkimi agentami i zadaniami w ramach całego procesu. Każdy agent ma przypisaną jasno określoną rolę oraz specjalizację, a każde zadanie zawiera informacje, który agent ma je wykonać. Dla uproszczenia obecnie każde zadanie obsługuje pojedynczy, wyspecjalizowany agent.

Pipeline działa sekwencyjnie. Zadania są wykonywane jedno po drugim. Po zakończeniu danego etapu jego wynik trafia do odpowiedniego agenta. Po „oddaniu” wyników agent znika i wywoływane jest kolejne zadanie w kolejce. Dzięki temu możemy precyzyjnie kontrolować przepływ informacji oraz logikę działania systemu. Zakres został celowo ograniczony do trybu sekwencyjnego, aby zachować przejrzystość i łatwość testowania.

Jedynym zewnętrznym komponentem całej architektury jest model językowy *LLM*, do którego wysyłamy konfiguracje agenta i dostajemy agenta odpowiednio skonfigurowanego do roli wykazanej w zadaniu. Jest możliwość podłączenia lokalnego modelu (np. *Bielik*, *Deepseek*, *Mistral*) za pomocą *LangChain*, co dałoby kompletnie lokalny system.

Wewnętrzna architektura opiera się na 4 agentach.

- **Ekspert porównujący narracje** – analizuje wiele artykułów na ten sam temat, identyfikując subtelne różnice w tonie, treści i doborze faktów, wskazujące na zmianę narracji.
  Wyniki przekazuje do **Agenta decyzyjnego**.

- **Analityk biasu i spinu** – wykrywa i klasyfikuje typy stronniczości i manipulacji językowej w artykułach zgodnie z ustaloną typologią biasu medialnego.
  Wyniki przekazuje do **Agenta decyzyjnego**.

- **Analityk tonu i manipulacji** – bada ton emocjonalny, ocenność i środki stylistyczne w języku artykułów w celu wykrycia tendencyjnych lub manipulacyjnych treści.
  Wyniki przekazuje do **Agenta decyzyjnego**.

- **Agent decyzyjny** – integruje analizy pozostałych agentów i formułuje końcową ocenę dotyczącą obecności manipulacji w artykule oraz jej charakteru i intensywności. Generuje finalny raport używając składni *markdown*.

2.2 Konstrukcja poleceń

Przekazywane agentom polecenia zostały zoptymalizowane pod kątem szybkości wykonywania oraz trafności odpowiedzi. Odpowiednie strategie zostały dobrane na podstawie prac [8] i [3] oraz eksperymentalnie na podstawie uzyskiwanych odpowiedzi.

Wykorzystane polecenia mają charakter instruktażowy. Istotna okazała się dbałość o ich jednoznaczność i precyzyjne instrukcje, tak aby odpowiedzi niezawodnie nie odbiegały od wyznaczonego zadania. Kolejnymi kluczowymi elementami były unikanie efektów ubocznych oraz przypadkowych sugestii w poleceniach. W naszym przypadku mogłoby to spowodować wymuszenie wyszukiwania nieistniejących lub wyolbrzymiania cech wskazujących na manipulację. Fragment przykładowego polecenia przedstawiono poniżej:

„Porównaj narrację i strukturę artykułów opisujących ten sam temat, ale pochodzących z różnych źródeł lub dat. Skoncentruj się na różnicach w tonie, selekcji faktów, emocjonalnym nacechowaniu, pominięciach lub przesunięciach w akcentach. Zidentyfikuj zmiany, które mogą świadczyć o subtelnej manipulacji treścią.”

3 Wyniki badań eksperymentalnych

W celu prezentacji działania prototypu oraz wstępnej weryfikacji jego poprawności przeprowadzane zostały eksperymenty na przykładowych artykułach portalu *Onet*. Jeden z wyników przedstawiony jest w listingu 1.

Zadaniem systemu było przeprowadzenie analizy i porównania artykułów prasowych [2] (artykuł A) oraz [5] (artykuł B). Oba opublikowane zostały 11. czerwca 2025 i poruszają ten sam temat wotum zaufania dla rządu Donalda Tuska po wyborach prezydenckich 2025. Różni autorzy jednak odmiennie podchodzą do prezentowanego zagadnienia.

Odpowiedź modelu jest tekstem w formacie *markdown* (1), będącym wynikiem pracy 4 agentów *AI*. Opis w podpunkcie *Porównanie narracji* jest podsumowaniem analizy dokonanej przez pierwszego agenta. Wskazuje on różnice pomiędzy artykułami – w tym przypadku określa ich różne cele. Kolejny *analityk* odpowiada za prezentowany ton. Wskazuje on na emocjonalne nacechowanie i dramatyzację w artykule A. W kolejnym punkcie przedstawiona jest analiza stronniczości przekazu – tzw. *biasu*, czyli efekt pracy trzeciego agenta. Wskazuje on na kilka elementów dotyczących użytego języka i selektywnego doboru faktów w obu artykułach. Ostatni członek zespołu *CrewAI* zajmuje się stworzeniem podsumowania oraz wyciągnięciem wniosków. Ocenia on poziom manipulacji artykułu A jako umiarkowany i przedstawia odpowiednie zalecenia dla czytelnika.

```
## Końcowa decyzja dotycząca artykułu

```

```
- **Czy występuje manipulacja:** Tak
- **Rodzaj manipulacji:** Emocjonalna, informacyjna (poprzez selektywny dobór informacji)
- **Poziom intensywności:** Umiarkowana

### Argumentacja na podstawie danych od pozostałych agentów:

1. **Porównanie narracji:**
   Agent porównujący narracje wskazuje, że artykuł A (którego dotyczy analiza tonu i biasu) skupia
    się na potencjalnych **negatywnych konsekwencjach** przegranego głosowania nad wotum zaufania,
    w przeciwieństwie do artykułu B, który prezentuje **bardziej neutralny i informacyjny ton**. Ta
    różnica sugeruje, że artykuł A może mieć na celu **wywołanie niepokoju** u czytelnika.

2. **Analiza tonu:**
   Agent analizujący ton identyfikuje liczne fragmenty nacechowane emocjonalnie, takie jak:
   - użycie słowa „**zdyscyplinować”** w odniesieniu do działań Tuska,
   - dramatyczne wyrażenie „**prawdziwy ”chaos**,
   - sugestie dotyczące negatywnych intencji prezydenta Dudy.

   Wskazano także na:
   - użycie języka sugerującego **opinię zamiast faktów**,
   - **dramatyzację, sugestywność, emocjonalne nacechowanie** i **wartościowanie**.

   Ogólny ton artykułu oceniono jako **perswazyjny i dramatyczny**, co potwierdza tezę o
    manipulacji emocjonalnej.

3. **Analiza biasu:**
   Agent analizujący bias wykrył kilka form stronniczości:
   - **Pozytywny spin/framing** – przedstawienie głosowania jako ”formalności”,
   - **Ograniczony wybór źródeł** – skupienie się na wypowiedziach premiera Tuska,
   - **Język emocjonalny** – słowa takie jak ”zwycięstwo”, ”gorycz porażki”, ”kapitulacja”,
   - **Pomijanie** – brak wzmianki o potencjalnych negatywnych scenariuszach,
   - **Brak krytycznej analizy**.

   Te elementy wskazują na **manipulację informacyjną**, polegającą na selektywnym doborze
    informacji i przedstawieniu ich w korzystnym świetle.

### Wnioski końcowe:

Artykuł _”Co, jeżeli Donald Tusk nie uzyska wotum zaufania? Ekspert: wtedy wybierze Andrzej Duda”_
    zawiera elementy:
- **manipulacji emocjonalnej** – przez dramatyzację i nacechowany język wywołujący niepokój,
- **manipulacji informacyjnej** – przez selektywny dobór i pomijanie informacji oraz brak
    krytycznej analizy.

**Poziom intensywności manipulacji:** umiarkowany – artykuł nie zawiera otwartych kłamstw, ale
    subtelnie wpływa na percepcję czytelnika.

**Zalecenie dla odbiorców:**
Zachować **krytyczne podejście**, porównywać informacje z innymi źródłami i mieć świadomość
    potencjalnej stronniczości.
```

Listing 1: Odpowiedź systemu zwracana w formacie *markdown*

3.1 Wnioski

Po manualnej ocenie obu źródeł, przedstawione w odpowiedzi spostrzeżenia i wnioski wydają się być trafne. Model zauważa wszystkie istotne elementy manipulacji. Problemem może być jedynie

skupienie uwagi na artykule z wyższym poziomem manipulacji i niedostateczna ocena drugiego z nich.

4 Podsumowanie i możliwości dalszej pracy

Przeprowadzona wstępna analiza działania systemu pokazuje, że współczesne modele *LLM* są w stanie skutecznie radzić sobie z analizą artykułów prasowych pod kątem wykrywania manipulacji, porównania artykułów oraz rozróżnienia *biasu* i tonu wypowiedzi. Szczegółowa ocena wymaga wykorzystania większej ilości danych do ewaluacji odpowiedzi systemu. Takie podejście umożliwiłoby również porównanie dostępnych modeli językowych.

System przygotowany jest do działania w języku polskim, ale konwersja na inne języki nie stanowiłaby problemu. Być może w dalszym rozwoju konieczna będzie zmiana języka na angielski, ze względu na łatwiej dostępne dane. Kolejną potencjalną modyfikacją jest zrównoleglenie pracy agentów. Dzięki obliczeniom w chmurze, działający sekwencyjnie system na razie nie stanowi problemu, ale równoległa praca agentów byłaby przydatna w przypadku skomplikowania systemu lub konieczności rezygnacji z tego rozwiązania.

Otwarty pozostaje temat detekcji dezinformacji oraz tzw. *fake newsów*. Zbiory danych konieczne przy ocenie takiej analizy są dostępne oraz pozytywne wyniki w pokrewnym zagadnieniu pozwalają na optymistyczne podejście co do możliwości skutecznego działania *LLM* w tym zakresie.

Uzyskany system stanowi solidną podstawę do dalszego rozwoju i udowadnia skuteczność proponowanego podejścia w analizie artykułów prasowych.

Bibliografia

[1] Z. Duan i J. Wang. „Exploration of LLM Multi-Agent Application Implementation Based on LangGraph+ CrewAI". W: *arXiv preprint arXiv:2411.18241* (2024).

[2] M. Gałczyńska. *Co, jeżeli Donald Tusk nie uzyska wotum zaufania? Ekspert: wtedy wybierze Andrzej Duda*. URL: https://wiadomosci.onet.pl/kraj/co-jezeli-donald-tusk-nie-uzyska-wotum-zaufania-ekspert-wtedy-wybierze-andrzej-duda/hv7hp7g (term. wiz. 20. 06. 2025).

[3] L. Giray. „Prompt engineering with ChatGPT: a guide for academic writers". W: *Annals of biomedical engineering* 51.12 (2023), s. 2629–2633.

[4] R. Jin, R. Fu, Z. Wen, S. Zhang, Y. Liu i J. Tao. *Fake News Detection and Manipulation Reasoning via Large Vision-Language Models*. 2024. arXiv: 2407.02042 [cs.CL]. URL: https://arxiv.org/abs/2407.02042.

[5] KMM. *Jasny wpis premiera przed głosowaniem o wotum zaufania. "Nie znam takiego słowa jak kapitulacja"*. URL: https://wiadomosci.onet.pl/kraj/wpis-premiera-przed-glosowaniem-o-wotum-zaufania-nie-znam-takiego-slowa/l1h2f5j (term. wiz. 20. 06. 2025).

[6] L. Lin, L. Wang, J. Guo i K.-F. Wong. „Investigating bias in llm-based bias detection: Disparities between llms and human perception". W: *arXiv preprint arXiv:2403.14896* (2024).

[7] F.-J. Rodrigo-Ginés, J. Carrillo-de-Albornoz i L. Plaza. „A systematic review on media bias detection: What is media bias, how it is expressed, and how to detect it". W: *Expert Systems with Applications* 237 (2024), s. 121641.

[8] J. White, Q. Fu, S. Hays, M. Sandborn, C. Olea, H. Gilbert, A. Elnashar, J. Spencer-Smith i D. C. Schmidt. „A prompt pattern catalog to enhance prompt engineering with chatgpt". W: *arXiv preprint arXiv:2302.11382* (2023).